

Linha de Pesquisa — IAUPE Analyzer: Extração de Editais de Fomento com LLM

Particularidade da Pesquisa

O IAUPE Analyzer foi desenvolvido como um sistema de produção, no contexto de um estágio institucional, e não como um experimento controlado de laboratório. Nesta etapa da pesquisa, o escopo está restrito a quatro fontes de fomento público de âmbito nacional brasileiro — FACEPE, CNPq, CAPES e FINEP —, sem cobertura de editais estaduais de outras unidades da federação ou de fontes internacionais. Além disso, a validação da solução, até o momento, foi conduzida de forma incidental, isto é, orientada pela observação do comportamento em produção, e não por um protocolo formal de avaliação com métricas de acurácia sobre um conjunto de teste rotulado.

Esta versão do desenho de pesquisa estabelece uma priorização explícita entre as duas hipóteses investigadas. Reduzir o esforço manual de acompanhamento (Hipótese 2) é uma capacidade necessária, mas não é, isoladamente, a contribuição central da pesquisa. O valor mais relevante está no direcionamento automático de cada edital aos interessados certos de sua área (Hipótese 1), permitindo que pesquisadores, departamentos e grupos de pesquisa se organizem com antecedência em torno das oportunidades relevantes. É esse direcionamento — e não apenas a economia de tempo de leitura — que se acredita capaz de gerar ganhos institucionais mais amplos, como aumento de recursos de fomento captados e maior visibilidade da instituição junto às agências financiadoras. A Hipótese 2 permanece necessária porque o direcionamento só é confiável na medida em que os campos extraídos de cada edital (área, público-alvo, prazo) forem extraídos corretamente; ela é tratada aqui como pré-condição técnica da Hipótese 1, não como seu equivalente em importância.

Pergunta de Pesquisa 1

É possível, a partir dos dados estruturados extraídos pela pipeline (áreas de interesse, segmentos e público-alvo), direcionar automaticamente cada edital aos pesquisadores, departamentos ou grupos de pesquisa mais aderentes de sua área, de modo que esses interessados possam se organizar com antecedência e a instituição venha a captar mais recursos e ganhar mais visibilidade junto às agências de fomento?

Objetivo

Desenvolver e avaliar uma pipeline automatizada, o IAUPE Analyzer, capaz de coletar, extrair, estruturar e, sobretudo, direcionar editais de fomento público aos pesquisadores, departamentos e grupos de pesquisa mais aderentes de cada área, para que estes possam se organizar com antecedência em torno das oportunidades relevantes. A extração confiável dos dados e a redução do esforço manual de acompanhamento são tratadas como capacidades habilitadoras desse direcionamento, e não como fim em si mesmas; o objetivo final é contribuir para o aumento dos recursos de fomento captados e da visibilidade da instituição junto às agências financiadoras.

Hipótese 1

O direcionamento automático de cada edital aos interessados certos de sua área — obtido pelo cruzamento entre os campos de classificação já extraídos pela pipeline (áreas de interesse, segmentos e público-alvo) e um cadastro de perfis institucionais (docentes,

departamentos, grupos de pesquisa) — permite que esses interessados se organizem com antecedência suficiente para preparar e submeter propostas mais competitivas. Como consequência, espera-se um aumento mensurável no volume de recursos de fomento captados pela instituição e ganho de visibilidade junto às agências financiadoras, em comparação com o cenário de acompanhamento manual e não direcionado.

Pergunta de Pesquisa 2

É possível construir uma pipeline automatizada, baseada em um LLM, capaz de extrair e estruturar com confiabilidade suficiente os campos essenciais de um edital de fomento público — incluindo documentos sem camada de texto extraível — de modo a viabilizar, como pré-condição técnica, o direcionamento automático investigado na Hipótese 1, reduzindo ao mesmo tempo o esforço manual de acompanhamento?

Hipótese 2

A extração dos campos essenciais de um edital (público-alvo, critérios de elegibilidade, cronograma, prazo de submissão e campos de classificação), realizada por um LLM orientado por prompt estruturado com vocabulário controlado, atinge precisão e recall por campo suficientes para sustentar o direcionamento automático da Hipótese 1 — inclusive em documentos sem camada de texto extraível, processados via OCR —, reduzindo também o esforço manual de acompanhamento. Trata-se de um ganho relevante, porém secundário diante do objetivo de direcionamento e captação de recursos.

Fontes de Dados Monitoradas

Cada fonte é coletada por uma estratégia distinta, adaptada à estrutura do respectivo portal ou API:

FACEPE

Coleta via requests combinado a um parser HTML próprio (BeautifulSoup), que filtra os editais principais do ano-alvo configurado e os ordena por data de publicação, mais recentes primeiro.

CNPq

Coleta em duas etapas: identificação, na listagem, de links diretos para PDF e de páginas de detalhe; para estas últimas, uma segunda requisição tolerante a falhas extrai os PDFs da página de detalhe. Ordenação pela data de início de inscrição, mais recentes primeiro.

CAPES

A página de índice é tratada como agregador de páginas de programa: coleta das URLs de cada programa, visita individual para extração dos documentos e filtragem pelo ano-alvo. Um cliente HTTP com novas tentativas e variação de host (www.gov.br / gov.br) lida com instabilidades de rede específicas desta fonte.

FINEP

Coleta inteiramente via API REST autenticada por OAuth2 (fluxo client credentials), consultando chamadas com situação “aberta” e buscando, em cada uma, o documento cujo

nome contenha “edital”, com fallback para o primeiro documento em formato PDF disponível.

Cálculo da Cobertura

A cobertura de cada fonte monitorada é calculada por:

$\text{Cobertura} = \text{Editais processados} / \text{Editais disponíveis no portal de origem}$

Onde:

- Editais processados corresponde ao número de documentos já coletados e submetidos à pipeline de extração, com sucesso ou falha;
- Editais disponíveis corresponde ao número total de editais atualmente publicados no portal de origem da fonte.

De forma complementar, a Taxa de sucesso é dada pela razão entre editais processados com sucesso e o total de editais processados na mesma fonte.

Estudo de Caso — Comparação de Cobertura entre Fontes

Objetivo

Comparar a cobertura alcançada pela pipeline entre as quatro fontes monitoradas, cruzando o número de editais disponíveis no portal de origem com o número de documentos já processados e armazenados.

Fontes Avaliadas

- FACEPE
- CNPq
- CAPES
- FINEP

Métricas Avaliadas

- Editais disponíveis no portal de origem
- Editais processados com sucesso
- Editais processados com falha
- Editais pendentes

Resultado Obtido

Os números apresentados no artigo são explicitamente marcados como desatualizados (registrados em uma execução anterior do script de checagem de cobertura, em data não determinada, e pendentes de nova execução antes da versão final). Ainda assim, indicam cobertura desigual entre fontes: FACEPE com 166 editais disponíveis e 65 processados (61 com sucesso, 4 com falha; 101 pendentes); CAPES com 72 disponíveis e apenas 1 processado com sucesso (71 pendentes); CNPq com 1 edital disponível, processado com sucesso; FINEP com 8 disponíveis e 1 processado com sucesso (7 pendentes). O artigo levanta, mas não testa formalmente, a hipótese de que essa disparidade reflita tanto diferenças

reais na frequência de publicação de cada instituição quanto possíveis limitações dos coletores específicos de CAPES, CNPq e FINEP.

Observação Metodológica

Trata-se de um levantamento descritivo da cobertura em produção, e não de um experimento comparativo controlado com hipótese pré-registrada, tampouco de uma avaliação de acurácia por campo extraído. Esses números evidenciam a viabilidade técnica da extração (Hipótese 2), pré-condição para o direcionamento investigado na Hipótese 1 — mas não avaliam, por si só, se esse direcionamento de fato ocorre nem se gera ganho de recursos ou visibilidade para a instituição.

Lacuna Experimental — Direcionamento e Ganho Institucional (Hipótese 1)

Situação Atual

Esta é a lacuna mais importante do desenho atual, e o artigo não a trata: ela é uma extensão proposta, não uma questão investigada no texto original. Hoje, o sistema permite que cada pesquisador marque manualmente editais de interesse na interface web (alternância de “estrela”) e recebe notificações por e-mail sobre novos editais e prazos próximos. Não há, porém, um mecanismo automático que associe um edital — a partir dos campos de classificação já extraídos com vocabulário controlado (áreas_interesse e segmentos) — a docentes, departamentos ou linhas de pesquisa específicas, nem qualquer medição de seu efeito sobre a organização dos interessados, os recursos captados ou a visibilidade institucional.

Procedimento Proposto

- Construir um cadastro de perfis de interessados (docentes, departamentos, grupos de pesquisa), categorizados segundo o mesmo vocabulário controlado já usado na extração (áreas_interesse, segmentos).
- Implementar uma etapa de correspondência (matching) entre os campos extraídos de cada edital e os perfis cadastrados, para direcionamento automático de notificações aos interessados específicos, com antecedência suficiente para organização da proposta.
- Comparar, para uma amostra de editais, o comportamento de submissão de grupos que receberam direcionamento automático com o de grupos que dependeram apenas do acompanhamento manual atual (desenho quase-experimental, já que a alocação não pode ser totalmente controlada).
- Acompanhar, ao longo de um ou mais ciclos de fomento, a evolução do volume de recursos captados e da participação da instituição nos editais monitorados.

Métricas a Avaliar

- Precisão e recall do direcionamento automático (edital correto → interessado correto)
- Tempo entre a publicação do edital e a notificação ao interessado correto, comparado ao fluxo manual atual
- Volume de recursos de fomento captados pela instituição (R\$) e número de propostas submetidas, antes e depois da adoção do direcionamento automático

- Indicadores de visibilidade institucional junto às agências de fomento (ex.: número de submissões, parcerias firmadas, menções institucionais)
- Percepção de utilidade por gestores e pesquisadores, coletada por entrevista ou questionário

Resultado Esperado

Evidência de que o direcionamento automático de editais aos interessados certos de cada área aumenta o tempo de preparação disponível para submissão e está associado a mais recursos de fomento captados e maior visibilidade da instituição junto às agências financiadoras, e não apenas a uma economia de tempo de leitura.

Lacuna Experimental — Confiabilidade da Extração (Hipótese 2)

Situação Atual

Segundo o próprio artigo (Seção VI-C), a hipótese de confiabilidade da extração não pôde ainda ser formalmente confirmada ou refutada: não foi conduzido um experimento controlado comparando o esforço e a confiabilidade do acompanhamento manual com os do acompanhamento automatizado pela pipeline. A evidência disponível é indireta — baseada na ausência de incidentes reportados em produção — e não em métricas de precisão, recall ou F1 por campo extraído. Como a Hipótese 2 é pré-condição técnica da Hipótese 1, essa lacuna deve ser fechada antes de, ou em paralelo a, qualquer avaliação do direcionamento automático.

Procedimento Proposto

- Construir um conjunto de teste rotulado manualmente, com os campos-alvo (público-alvo, critérios de elegibilidade, cronograma, prazo de submissão e campos de classificação) anotados por um avaliador humano, para uma amostra de editais de cada fonte.
- Comparar, campo a campo, a saída da pipeline com o gabarito rotulado.
- Comparar o tempo/esforço do acompanhamento manual com o do uso da pipeline, para testar o componente da hipótese relativo à redução de esforço.

Métricas a Avaliar

- Precisão, recall e F1 por campo extraído, incluindo os campos de classificação (áreas_interesse, segmentos) usados pelo direcionamento
- Taxa de erro por tipo (formato de data, raciocínio numérico, falha herdada do OCR), na linha da taxonomia usada pelo estudo publicado na Electronics
- Esforço/tempo de acompanhamento manual vs. automatizado

Resultado Esperado

Confirmação ou refutação formal da hipótese, com evidência quantitativa por campo, aproximando o rigor de avaliação do IAUPE Analyzer do adotado por Moreira-Filho et al. e pelo estudo publicado na Electronics. Um resultado positivo aqui é a condição de partida para que o direcionamento da Hipótese 1 seja confiável.